

A tensor based reduced order model for parametric interpolation for reactive flows

Isacco Faglioni¹, Chiara Novelli², Alessandro Parente^{2,3} and Soledad Le Clainche¹

¹School of Aeronautical and Space Engineering, Universidad Politécnica de Madrid, Madrid, Spain

²Aero-Thermo-Mechanics Department, Université Libre de Bruxelles, Brussels, Belgium

³Brussels Institute for Thermal-fluid Systems and Clean Energy (BRITE), ULB and VUB, Belgium

E-mail: isacco.faglioni@alumnos.upm.es

Abstract. Questo lavoro presenta un modello d'ordine ridotto per l'interpolazione parametrica di flussi reattivi basato sulla Higher-Order Singular Value Decomposition (HOSVD) combinata con la Gaussian Process Regression (GPR). Rispetto al classico approccio POD+GPR, il metodo proposto sfrutta la struttura tensoriale dei dati di addestramento organizzati su una griglia cartesiana nello spazio dei parametri, disaccoppiando i modi parametrici da quelli spaziali. Due GPR univariati sostituiscono il singolo GPR bivariato, riducendo la dimensione effettiva del problema di regressione. Gli iperparametri dei kernel sono selezionati tramite una ricerca a griglia su un insieme di validazione dedicato. Il metodo è validato su un dataset di 100 simulazioni CFD di una fiamma a diffusione di idrogeno turbolenta, parametrizzate dal numero di Reynolds e dalla frazione di massa del combustibile su una griglia 10×10 . HOSVD+GPR supera sistematicamente POD+GPR in termini di errore ℓ^2 relativo per tutti e sei i campi esaminati (temperatura, CH_4 , O_2 , CO , CO_2 , H_2O), con vantaggi più marcati nei punti di test in cui entrambi i parametri non sono presenti nella griglia di addestramento.

Keywords: Reduced Order Modeling, HOSVD, Parametric Interpolation, Digital Twins, Reactive Flows

1. Introduction

The development of digital twins for reactive flows is one of the most important steps towards industry decarbonization. Being able to accurately reproduce the behaviour of a system allows to optimize industrial processes, improve energy efficiency and control strategies. Classical computational fluid dynamics (CFD) generates high fidelity simulations of how a system evolves, but due to the fact that it is often expensive and time consuming it cannot provide a continuous profile of the behaviour of the system. For this reason algorithms that upsample or super resolve the operational parametric space currently are a growing branch of research. The main goal is that of leveraging the information contained in the high fidelity CFD data to train a model able to generate a simulation of the system under new operating conditions in a fraction of the time.

This work presents a novel reduced order model (ROM) based on the higher order singular value decomposition (HOSVD) for parametric interpolation of reactive flows. Section AAAA presents the current methods used for parametric interpolation and their limitations. Section BBBB describes the proposed method and its advantages. Finally, Section CCCC presents the results of the method on a test case and compares it with existing methods.

2. Related Work

2.1. SVD based Reduced Order Models

SVD has been used for reduced order modeling of fluid flows, reactive or not, since ANNO E CITAZIONE. The mathematical idea behind this class of algorithms is that of rearranging data into matricial form, decompose it with SVD and extracting a low dimensional rapresentaion of the system from the leading eigenvectors associated to the largest singular values. Depending on how data is preprocessed and rearranged the algorithms assume different names:

La Proper Orthogonal Decomposition (POD), nota anche come Analisi delle Componenti Principali (PCA) in ambito statistico, è la tecnica di riduzione dimensionale lineare più diffusa in fluidodinamica. Data una collezione di snapshot di flusso, la POD estrae un insieme di modi spaziali ordinati per contenuto energetico; ogni snapshot dell'ensemble può essere approssimato come combinazione lineare dei modi dominanti. I coefficienti di questa espansione, detti coefficienti POD, catturano la dipendenza dalle condizioni operative e sono molto più economici da interpolare rispetto ai campi completi ad alta dimensionalità.

La Regressione a Processi Gaussiani (GPR) offre un'alternativa probabilistica che quantifica naturalmente l'incertezza della predizione [1]; la sua combinazione con la POD è stata impiegata con successo nella costruzione di digital twin per flussi reattivi [2] e per la caratterizzazione stocastica di fiamme [3]. Un limite comune dei surrogati POD+GPR è che il problema di interpolazione dei coefficienti diventa più difficile all'aumentare del numero di parametri: un GPR multivariato che mappa tuple di condizioni operative in

coefficienti POD deve essere addestrato su osservazioni sparse e soffre della maledizione della dimensionalità.

2.2. Metodi tensoriali in meccanica dei fluidi

Le decomposizioni tensoriali generalizzano la SVD matriciale ad array di ordine superiore e sono strumenti naturali quando i dati possiedono una struttura multi-modale. La decomposizione Higher-Order SVD (HOSVD) [4] fattorizza un tensore a N vie in un array nucleo e un insieme di matrici fattore, una per modo. Rispetto alla decomposizione Canonical Polyadic (CP), il formato HOSVD è più semplice da calcolare (ciascuna matrice fattore si ottiene tramite una SVD matriciale standard) e conserva meglio la struttura quando i modi hanno significato fisico diverso.

Nel contesto parametrico, organizzare gli snapshot su una griglia strutturata nello spazio dei parametri consente di trattare separatamente i modi parametrici e i modi spaziali/spettrali: questo è il principio chiave sfruttato nel presente lavoro.

2.3. GPR per surrogati ingegneristici

Il GPR è un metodo bayesiano non parametrico che pone una distribuzione a priori sullo spazio delle funzioni [1]. Per spazi di ingresso a bassa dimensionalità è altamente competitivo, offrendo inferenza a posteriori in forma chiusa e stime analitiche dell'incertezza. La famiglia di kernel di Matérn è particolarmente diffusa nelle applicazioni ingegneristiche perché controlla la regolarità della funzione predetta tramite un singolo parametro ν ; la scelta $\nu = 5/2$ è comune in quanto garantisce differenziabilità in senso quadratico medio fino al secondo ordine.

Combinato con un passo di riduzione dimensionale lineare, il GPR è stato applicato con successo ai flussi reattivi [2,3]. Il presente contributo si distingue dalla letteratura POD+GPR esistente in quanto sostituisce il singolo GPR multidimensionale con due GPR univariati indipendenti, reso possibile dalla struttura HOSVD dei dati di addestramento.

3. Metodologia

3.1. Formulazione del problema

Sia $\boldsymbol{\mu} = (\mu_1, \mu_2) \in \mathcal{P} \subset \mathbb{R}^2$ una coppia di parametri operativi. Per ciascun $\boldsymbol{\mu}$, un solutore CFD ad alta fedeltà produce un campo di flusso multi-specie discretizzato su una mesh strutturata 2-D di $N_z \times N_r$ celle, ottenendo uno snapshot

$$\mathbf{S}(\boldsymbol{\mu}) \in \mathbb{R}^{N_z \times N_r \times N_{\text{sp}}}, \quad (1)$$

dove N_{sp} è il numero di specie trasportate e di quantità termodinamiche. Nel caso di studio, i parametri operativi sono il numero di Reynolds ($\mu_1 = Re$) e la frazione di massa di idrogeno al combustibile ($\mu_2 = X_{\text{H}_2}$). Dato un insieme di addestramento di

N_{train} snapshot in posizioni parametriche note $\{\boldsymbol{\mu}^{(k)}\}_{k=1}^{N_{\text{train}}}$, l'obiettivo è predire $\mathbf{S}(\boldsymbol{\mu}^*)$ in un nuovo punto di test $\boldsymbol{\mu}^*$ senza eseguire il solutore CFD completo.

3.2. Pre-elaborazione dei dati

Tutti gli snapshot vengono normalizzati usando le statistiche calcolate esclusivamente sul set di addestramento, per evitare la contaminazione dei dati di test. Per ciascuna specie/quantità s , la media μ_s e la deviazione standard σ_s di addestramento sono calcolate su tutte le celle e tutti i casi di addestramento. Lo snapshot normalizzato è

$$\tilde{\mathbf{S}}(\boldsymbol{\mu}) = \frac{\mathbf{S}(\boldsymbol{\mu}) - \mu_s}{\sigma_s}. \quad (2)$$

Le quantità con deviazione standard nulla (campi costanti) vengono lasciate invariate. Tutti i modelli surrogati operano sui dati normalizzati; le predizioni vengono ritrasformate prima del calcolo degli errori.

3.3. POD + GPR (metodo di riferimento)

Gli snapshot di addestramento vengono appiattiti e impilati in una matrice

$$\mathbf{M} \in \mathbb{R}^{(N_z N_r N_{\text{sp}}) \times N_{\text{train}}}, \quad (3)$$

su cui viene eseguita una SVD troncata: $\mathbf{M} = \mathbf{V}\boldsymbol{\Sigma}\mathbf{W}^\top$. I modi spaziali $\mathbf{V}$ vengono mantenuti fino a una soglia di energia cumulativa del 99%, ottenendo r_{POD} modi. I vettori di coefficienti POD

$$\mathbf{a}(\boldsymbol{\mu}^{(k)}) = \mathbf{V}_{:,1:r}^\top \mathbf{M}_{:,k} \in \mathbb{R}^{r_{\text{POD}}} \quad (4)$$

vengono poi usati come target per un GPR bivariato con ingresso $\boldsymbol{\mu} = (\mu_1, \mu_2)$. Il kernel è un prodotto tra un'ampiezza costante e un kernel base:

$$k(\boldsymbol{\mu}, \boldsymbol{\mu}') = \sigma_f^2 k_{\text{base}}(\boldsymbol{\mu}, \boldsymbol{\mu}'; \ell_1, \ell_2), \quad (5)$$

dove la famiglia k_{base} e la lunghezza scala ℓ sono selezionate tramite una ricerca a griglia su un set di validazione dedicato (cfr. Sezione 4). Un GPR separato viene adattato per ciascun indice di modo POD (formulazione multi-output). Al punto di test $\boldsymbol{\mu}^*$, i coefficienti predetti $\hat{\mathbf{a}}$ vengono usati per ricostruire il campo:

$$\hat{\mathbf{S}}_{\text{POD}}(\boldsymbol{\mu}^*) = \mathbf{V}_{:,1:r} \hat{\mathbf{a}}. \quad (6)$$

3.4. HOSVD + GPR (metodo proposto)

3.4.1. Organizzazione tensoriale Quando gli snapshot di addestramento sono disponibili su una griglia regolare $\{\mu_1^{(i)}\}_{i=1}^{n_1} \times \{\mu_2^{(j)}\}_{j=1}^{n_2}$, con $N_{\text{train}} = n_1 n_2$, i dati ammettono una naturale rappresentazione tensoriale:

$$\mathcal{T} \in \mathbb{R}^{n_1 \times n_2 \times N_z \times N_r \times N_{\text{sp}}}, \quad \mathcal{T}_{i,j,:,:,} = \tilde{\mathbf{S}}(\mu_1^{(i)}, \mu_2^{(j)}). \quad (7)$$

I primi due modi corrispondono agli assi parametrici, mentre i restanti tre sono modi spaziali e spettrali.

3.4.2. *Higher-Order SVD* L'HOSVD [4] fattorizza $\mathcal{T}$ tramite una sequenza di dispiegamenti per modo. Per ciascun modo $n \in \{1, \dots, 5\}$, viene calcolato il dispiegamento $\mathbf{T}_{(n)}$ e ne vengono estratti i vettori singolari sinistri:

$$\mathbf{T}_{(n)} = \mathbf{U}_n \mathbf{\Sigma}_n \mathbf{V}_n^\top, \quad \mathbf{U}_n \in \mathbb{R}^{d_n \times d_n}, \quad (8)$$

dove d_n è la dimensione del modo n . La matrice fattore $\mathbf{U}_n$ viene poi troncata alle sue r_n colonne dominanti, con r_n scelto per mantenere il 99% dell'energia spettrale. Il nucleo di Tucker si ottiene per proiezione multi-modale:

$$\mathcal{G} = \mathcal{T} \times_1 \mathbf{U}_1^\top \times_2 \mathbf{U}_2^\top \times_3 \mathbf{U}_3^\top \times_4 \mathbf{U}_4^\top \times_5 \mathbf{U}_5^\top, \quad \mathcal{G} \in \mathbb{R}^{r_1 \times r_2 \times r_3 \times r_4 \times r_5}. \quad (9)$$

Il tensore originale è recuperato esattamente (entro la soglia energetica) come

$$\mathcal{T} \approx \mathcal{G} \times_1 \mathbf{U}_1 \times_2 \mathbf{U}_2 \times_3 \mathbf{U}_3 \times_4 \mathbf{U}_4 \times_5 \mathbf{U}_5. \quad (10)$$

3.4.3. *GPR sulle righe fattore parametriche* Le righe delle matrici fattore parametriche $\mathbf{U}_1 \in \mathbb{R}^{n_1 \times r_1}$ e $\mathbf{U}_2 \in \mathbb{R}^{n_2 \times r_2}$ codificano come la decomposizione varia lungo ciascun asse parametrico in modo indipendente. Invece di un singolo GPR bivariato, vengono addestrati due GPR *univariati* separati:

$$\text{GPR}_1 : \mu_1 \mapsto \mathbf{u}_1(\mu_1) \in \mathbb{R}^{r_1}, \quad (11)$$

$$\text{GPR}_2 : \mu_2 \mapsto \mathbf{u}_2(\mu_2) \in \mathbb{R}^{r_2}. \quad (12)$$

Ciascun GPR usa un kernel di Matérn-2.5 con un singolo scalare di lunghezza scala, appropriato per un ingresso monodimensionale; la lunghezza scala è selezionata tramite il tuner. Al punto di test $\boldsymbol{\mu}^* = (\mu_1^*, \mu_2^*)$, le righe fattore predette $\hat{\mathbf{u}}_1$ e $\hat{\mathbf{u}}_2$ vengono usate per contrarre parzialmente il nucleo di Tucker:

$$\hat{\mathcal{G}}' = \mathcal{G} \times_1 \hat{\mathbf{u}}_1 \times_2 \hat{\mathbf{u}}_2 \in \mathbb{R}^{r_3 \times r_4 \times r_5}. \quad (13)$$

La ricostruzione completa del campo si ottiene espandendo i modi spaziali e spettrali residui:

$$\hat{\mathbf{S}}_{\text{HOSVD}}(\boldsymbol{\mu}^*) = \hat{\mathcal{G}}' \times_3 \mathbf{U}_3 \times_4 \mathbf{U}_4 \times_5 \mathbf{U}_5. \quad (14)$$

3.4.4. *Vantaggi rispetto a POD + GPR* Due vantaggi strutturali distinguono l'approccio HOSVD da POD+GPR. In primo luogo, i modi parametrici e i modi spaziali/spettrali sono separati *per costruzione*; il nucleo di Tucker funge da tensore di accoppiamento, ma il GPR opera soltanto sulle righe fattore a bassa dimensionalità, non sui coefficienti di campo compressi. In secondo luogo, sostituire un singolo GPR bivariato con due GPR univariati riduce la dimensione effettiva dell'ingresso di ciascun problema di regressione, il che migliora l'efficienza campionaria e il condizionamento numerico [1]. Ciò è particolarmente vantaggioso quando uno o entrambi i parametri di test si trovano al di fuori dell'involucro convesso della griglia di addestramento, ossia in regime di estrapolazione.

3.5. Metrica di errore

La qualità della predizione viene valutata tramite l'errore relativo ℓ^2 per specie:

$$\varepsilon_s = \frac{\|\hat{F}_s - F_s^{\text{true}}\|_F}{\|F_s^{\text{true}}\|_F}, \quad (15)$$

dove $\|\cdot\|_F$ denota la norma di Frobenius sulla griglia spaziale e F_s è il campo 2-D della quantità s .

4. Esperimenti

4.1. Dataset: simulazioni di flusso reattivo a idrogeno

Il dataset consiste di 100 simulazioni CFD ad alta fedeltà di una fiamma a diffusione di idrogeno turbolenta su una mesh assialsimmetrica 2-D. I due parametri operativi sono il numero di Reynolds Re e la frazione di massa di idrogeno all'ingresso del combustibile X_{H_2} , campionati su una griglia cartesiana uniforme 10×10 :

$$Re \in \{11000, 12000, \dots, 20000\}, \quad (16)$$

$$X_{\text{H}_2} \in \{0.04, 0.06, 0.08, 0.10, 0.12, 0.14, 0.16, 0.18, 0.20, 0.22\}. \quad (17)$$

Ciascuna simulazione fornisce la distribuzione spaziale 2-D di 44 quantità su una mesh $N_z \times N_r$, tra cui la temperatura T , le frazioni di massa delle specie e le quantità turbolente. Per la valutazione quantitativa lo studio si concentra su sei campi rappresentativi: la temperatura T e le frazioni di massa di CH_4 , O_2 , CO , CO_2 e H_2O , che costituiscono le quantità di maggiore interesse nelle applicazioni di combustione.

4.2. Suddivisione addestramento/test

La valutazione finale dei due metodi surrogati viene eseguita con il seguente protocollo. Il set di addestramento è composto dai $9 \times 9 = 81$ casi ottenuti escludendo l'intera riga $Re = 15000$ e l'intera colonna $X_{\text{H}_2} = 0.10$ dalla griglia 10×10 :

$$Re_{\text{train}} = \{11000, 12000, 13000, 14000, 16000, 17000, 18000, 19000, 20000\}, \quad (18)$$

$$X_{\text{H}_2, \text{train}} = \{0.04, 0.06, 0.08, 0.12, 0.14, 0.16, 0.18, 0.20, 0.22\}. \quad (19)$$

Entrambi i metodi ricevono gli stessi 81 snapshot di addestramento. I metodi vengono valutati su tutti e 100 i casi della griglia, con particolare interesse per i punti in cui $Re = 15000$ (non visto) o $X_{\text{H}_2} = 0.10$ (non visto): tali combinazioni richiedono un'interpolazione lungo la rispettiva dimensione parametrica.

4.3. Selezione degli iperparametri dei kernel

Gli iperparametri dei kernel GPR vengono selezionati tramite una ricerca a griglia esaustiva su un set di validazione dedicato, separato dal set di test finale, usando lo

script `tuner.py`. In questa fase il set di addestramento è:

$$Re_{\text{val-train}} = \{11000, 12000, 14000, 15000, 16000, 17000, 19000, 20000\}, \quad (20)$$

$$X_{\text{H}_2, \text{val-train}} = X_{\text{H}_2, \text{train}}, \quad (21)$$

e il set di validazione è $Re_{\text{val}} = \{13000, 18000\}$, $X_{\text{H}_2, \text{val}} = 0.10$.

La ricerca spazia su $9 \times 6 \times 9 = 486$ configurazioni, combinando:

- lunghezza scala del kernel 1-D (per i GPR HOSVD): $\ell_{1D} \in \{0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0, 1.5, 2.0\}$;
- famiglia di kernel 2-D (per il GPR POD): Matérn-0.5, Matérn-1.5, Matérn-2.5, RBF, RatQuad- $\alpha = 1$, RatQuad- $\alpha = 5$;
- lunghezza scala del kernel 2-D: stessa griglia di ℓ_{1D} .

La famiglia del kernel 1-D è fissata a Matérn-2.5, poiché con soli 8 punti di addestramento lungo l'asse Re la scelta della famiglia non è discriminante quanto quella della lunghezza scala. La configurazione ottimale viene selezionata minimizzando la somma degli errori medi HOSVD+GPR e POD+GPR sul set di validazione.

4.4. Struttura tensoriale HOSVD

Per il metodo HOSVD, gli 81 snapshot di addestramento vengono organizzati sulla griglia parametrica 9×9 , ottenendo un tensore a 5 vie $\mathcal{T} \in \mathbb{R}^{9 \times 9 \times N_z \times N_r \times N_{\text{sp}}}$. La soglia energetica per il troncamento dei modi è fissata al 99% per tutti i modi. I ranghi di Tucker $(r_1, r_2, r_3, r_4, r_5)$ vengono determinati automaticamente da questo criterio.

4.5. Implementazione dei GPR

Per entrambi i metodi si usa un kernel prodotto tra un'ampiezza costante σ_f^2 e un kernel base. La lunghezza scala è tenuta fissa al valore selezionato dal tuner; solo l'ampiezza σ_f^2 viene ottimizzata massimizzando la log-verosimiglianza marginale. Il metodo HOSVD impiega due GPR univariati indipendenti (uno per l'asse Re , uno per l'asse X_{H_2}), addestrati rispettivamente sulle righe di $\mathbf{U}_1$ e $\mathbf{U}_2$. Il metodo POD impiega un singolo GPR bivariato con lunghezze scala anisotrope corrispondenti a Re e X_{H_2} . In entrambi i casi gli ingressi vengono normalizzati nell'intervallo $[0, 1]$ usando il range di addestramento prima dell'adattamento.

Tutti gli esperimenti sono implementati in Python usando `scikit-learn` per il GPR e operazioni tensoriali native su `NumPy` per la decomposizione HOSVD e i prodotti modali.

5. Risultati

5.1. Decadimento energetico degli spettri singolari

La figura 1 mostra gli spettri di valori singolari normalizzati per ciascun modo HOSVD e per la decomposizione POD degli stessi dati di addestramento.

Table 1. Schema riassuntivo della configurazione sperimentale per entrambi i metodi surrogati.

	POD + GPR	HOSVD + GPR
Riduzione dimensionale	SVD su matrice appiattita	Tucker (HOSVD) su tensore a 5 vie
Soglia energetica	99%	99% per modo
Surrogato	1 GPR bivariato	2 GPR univariati
Dimensione ingresso GPR	2 (Re , X_{H_2})	1 (solo Re / solo X_{H_2})
Famiglia kernel	selezionata dal tuner	Matérn-2.5 (fissata)
Lunghezza scala	selezionata dal tuner	selezionata dal tuner
Casi di addestramento	81 (griglia 9×9)	81 (griglia 9×9)
Campi valutati	T , CH_4 , O_2 , CO , CO_2 , H_2O	




Figure 1. Spettri di valori singolari normalizzati per i cinque modi tensoriali HOSVD e per la POD (matrice appiattita). La linea tratteggiata indica il rango di troncamento r_n al 99% di energia cumulativa. Il rapido decadimento di tutti gli spettri conferma che una rappresentazione compatta è ottenibile. I modi parametrici (Re e X_{H_2}) presentano la più bassa dimensionalità intrinseca.

Il rapido decadimento dei valori singolari per i modi spaziali e spettrali indica che un'approssimazione Tucker a basso rango cattura quasi tutta la varianza nei dati di addestramento. I modi parametrici (Re e X_{H_2}) raggiungono la soglia energetica a rango basso a causa della piccola dimensione della griglia parametrica.

5.2. Selezione degli iperparametri

La figura 2 riporta la mappa di calore dell'errore combinato (HOSVD + POD) in funzione delle lunghezze scala ℓ_{1D} e ℓ_{2D} per ciascuna famiglia di kernel 2-D. La casella rossa indica la configurazione ottimale selezionata.

Le figure 3 e 4 mostrano l'errore per campo della configurazione ottimale sui due punti di validazione.

5.3. Accuratezza della ricostruzione

La figura 5 mostra l'errore medio relativo in funzione di X_{H_2} per tutti i valori di Re nella griglia, confrontando HOSVD+GPR e POD+GPR. Le linee verticali tratteggiate indicano i valori di X_{H_2} presenti nel set di addestramento; il punto $X_{H_2} = 0.10$ (non visto) è il caso di interpolazione più critico.

La figura 6 riporta l'errore medio per campo calcolato sui punti di test non visti




Figure 2. Ricerca a griglia congiunta su $\ell_{1D} \times$ (famiglia kernel 2-D $\times \ell_{2D}$). Ogni pannello mostra l'errore relativo medio combinato (HOSVD+GPR + POD+GPR) sul set di validazione $Re \in \{13000, 18000\}$, $X_{H_2} = 0.10$. La casella rossa indica la configurazione globalmente ottimale.




Figure 3. Errore relativo ℓ^2 per campo al punto di validazione $(Re, X_{H_2}) = (13000, 0.10)$ con la configurazione kernel ottimale. Blu: HOSVD+1D GPR; arancione: POD+2D GPR.

(ovvero le combinazioni per cui Re o X_{H_2} non appartengono al set di addestramento).

HOSVD+GPR supera sistematicamente POD+GPR su tutti e sei i campi. Il miglioramento è attribuibile alla separazione degli assi parametrici, che consente a ciascun GPR 1-D di sfruttare la struttura liscia e monodimensionale dei dati lungo il proprio asse, e alla codifica algebrica dell'interazione tra i parametri nel nucleo di Tucker.




Figure 4. Errore relativo ℓ^2 per campo al punto di validazione $(Re, X_{H_2}) = (18000, 0.10)$ con la configurazione kernel ottimale.




Figure 5. Errore relativo medio in funzione di X_{H_2} per tutti i valori di Re testati. Le linee verticali tratteggiate indicano i valori di X_{H_2} nel set di addestramento. HOSVD+1D GPR (blu) e POD+2D GPR (arancione).




Figure 6. Errore relativo ℓ^2 medio per campo, calcolato su tutti i punti di test non visti. HOSVD+GPR (blu) supera POD+GPR (arancione) su tutti e sei i campi.

5.4. Confronto dei campi spaziali

Le figure 7–12 mostrano le distribuzioni spaziali 2-D dei campi ricostruiti al punto di test $(Re, X_{H_2}) = (15000, 0.10)$, in cui sia Re che X_{H_2} sono non visti durante l’addestramento. Per ciascun campo sono mostrate la soluzione CFD di riferimento, la ricostruzione HOSVD, la ricostruzione POD, la distribuzione degli errori e le mappe di errore spaziale.

6. Conclusione

In questo lavoro è stato proposto un metodo surrogato per la predizione di campi fluidodinamici reattivi parametrici basato sulla decomposizione Tucker (HOSVD)




Figure 7. Campo di temperatura T a $(Re, X_{H_2}) = (15000, 0.10)$. Riga superiore: soluzione di riferimento, ricostruzione HOSVD+GPR, ricostruzione POD+GPR. Riga inferiore: distribuzione degli errori e mappe di errore spaziale (scala divergente, simmetrica rispetto allo zero).




Figure 8. Campo di frazione di massa CH_4 a $(Re, X_{H_2}) = (15000, 0.10)$. Stesso schema della figura 7.




Figure 9. Campo di frazione di massa O₂ a $(Re, X_{H_2}) = (15000, 0.10)$. Stesso schema della figura 7.




Figure 10. Campo di frazione di massa CO₂ a $(Re, X_{H_2}) = (15000, 0.10)$. Stesso schema della figura 7.




Figure 11. Campo di frazione di massa H₂O a $(Re, X_{H_2}) = (15000, 0.10)$. Stesso schema della figura 7.




Figure 12. Campo di frazione di massa CO a $(Re, X_{H_2}) = (15000, 0.10)$. Stesso schema della figura 7.

combinata con regressione a processi gaussiani (GPR). Il metodo sfrutta la struttura tensoriale dei dati di addestramento, organizzati su una griglia cartesiana nello spazio dei parametri, per disaccoppiare le modalità parametriche dalle modalità spaziali. Due GPR univariati, uno per l'asse del numero di Reynolds e uno per l'asse della frazione di massa del combustibile, sostituiscono il singolo GPR bivariato impiegato nell'approccio classico POD+GPR.

I risultati sperimentali su un dataset di 100 simulazioni di fiamma a diffusione di idrogeno mostrano che HOSVD+GPR supera sistematicamente POD+GPR in termini di errore relativo ℓ^2 su tutti e sei i campi esaminati (temperatura, CH₄, O₂, CO, CO₂, H₂O), con un miglioramento più marcato per i campi a variazione nonlineare più intensa. Il vantaggio è riconducibile a due fattori strutturali: la separazione delle modalità parametriche riduce la dimensione effettiva del problema di regressione, e il nucleo di Tucker codifica algebricamente l'interazione tra i parametri, sollevando il GPR dall'onere di modellarla statisticamente.

Lavori futuri includeranno l'estensione del metodo a spazi parametrici di dimensione superiore (ad esempio aggiungendo la geometria del bruciatore come parametro), l'adozione di kernel più espressivi o reti neurali come surrogati per i coefficienti delle modalità, e la validazione su dataset con geometrie tridimensionali. Si prevede inoltre di investigare strategie adattive per la selezione del set di addestramento in modo da massimizzare l'accuratezza del surrogato con il minor numero possibile di simulazioni CFD.

- [1] Williams C and Rasmussen C 1995 *Advances in neural information processing systems* **8**
- [2] Aversano G, Ferrarotti M and Parente A 2021 *Proceedings of the Combustion Institute* **38** 5373–5381
- [3] Procacci A, Iavarone S, Coussement A and Parente A 2025 *Proceedings of the Combustion Institute* **41** 105981
- [4] De Lathauwer L, De Moor B and Vandewalle J 2000 *SIAM journal on Matrix Analysis and Applications* **21** 1253–1278